

# Real-time prediction of nuclear power plant parameter trends following operator actions

实时预测操作员操作后的核电站参数趋势

陈鸿煜

Update date: 2023/5/26

Pub date: 2021


为了在核电站中实现快速准确的未来参数趋势预测，文章提出了一个**由多步预测策略和人工神经网络组成的数据驱动预测模型**(a data-driven prediction model composed of a multi-step prediction strategy and artificial neural networks)。

为了找到最佳模型性能，文章应用了多层感知机（Multi-Layer Perceptron, MLP）、循环神经网络和长短期记忆（LSTM）网络，并用核电站模拟器生成的应急运行数据训练了各种候选模型。应用结果表明，具有**多输入多输出策略和LSTM网络的预测模型**能够成功地解决在多种紧急情况下考虑操作员行动的未來参数趋势估计的多变量问题。

## 一、前置知识

### 1. 多层感知器MLP

首先介绍感知器(Perceptron Learning Algorithm, PLA)，是一个线性的二分类器，但不能对非线性的数据并不能进行有效的分类。示意图如下所示：



<http://blog.csdn.net/xhohes>

单层只能进行二分类，为了进行多分类，就需要增加层数。


具体如何选择层数，以及如何进行梯度下降，需要进一步学习。

## 2. LSTM

### (1). 概念

递归神经网络的神经元有一个不可见的隐藏状态。在这些神经元中，当输入被依次给出时，**隐藏状态被更新**，并在下一个输入被给出时通过。隐态反馈的优点是通过在隐态中反映过去的输入来记忆。因此，RNN擅长处理连续的数据，其中当前和过去的值具有依赖性。本研究中的vanilla RNN是最简单的RNN，在单元中包含三种权重。每个vanilla RNN单元的隐藏状态被更新为激活函数的输出值，输入和前一个隐藏状态的加权和被给定。每个单元的输出是当前隐藏状态的加权和。

LSTM是一种特殊的**递归神经网络**。这种网络与一般的前馈神经网络不同，LSTM可以利用时间序列对输入进行分析；简而言之，当使用前馈神经网络时，神经网络会认为 $t$ 时刻输入的内容与 $t + 1$ 时刻输入的内容**完全无关**，对于许多情况，例如图片分类识别，这是毫无问题的，可是对于一些情景，例如**自然语言处理** (NLP, Natural Language Processing) 或者我们需要分析类似于**连拍照片**这样的数据时，合理运用 $t$ 或之前的输入来处理 $t + n$ 时刻显然可以更加合理的运用输入的信息。为了运用到时间维度上信息，人们设计了**递归神经网络** (RNN, Recurssion Neural Network)，一个简单的递归神经网络如下图所示：



在图中， $x_t$  是在  $t$  时刻的输入信息， $h_t$  是在  $t$  时刻的输出信息，我们可以看到神经元  $A$  会递归的调用自身并且将  $t - 1$  时刻的信息传递给  $t$  时刻。递归神经网络在许多情况下运行良好，特别是在对**短时间序列**数据的分析时十分方便。但是，处理长时间序列数据时，性能会有所下降：


**长期依赖问题**：经过许多阶段传播后的梯度倾向于消失（大部分情况）或爆炸（很少，但对优化过程影响很大）。对于梯度爆炸是很好解决的，可以使用梯度修剪（**Gradient Clipping**），即当梯度向量大于某个阈值，缩放梯度向量。但对于梯度消失是很难解决的。

LSTM从被设计之初就被用于解决一般递归神经网络中普遍存在的**长期依赖问题**，使用LSTM可以有效的传递和表达长时间序列中的信息并且不会导致长时间前的有用信息被忽略（遗忘）。与此同时，LSTM还可以解决RNN中的梯度消失/爆炸问题。

LSTM的设计者提出了“长短期记忆”的概念——只有一部分的信息需要长期的记忆，而有的信息可以不记下来。同时，我们还需要一套机制可以动态的处理神经网络的“记忆”，因为有的信息可能一开始价值很高，后面价值逐渐衰减，这时候我们也需要让神经网络学会“遗忘”特定的信息。


## (2). 具体解释

一个使用  $\tanh$  函数的RNN可以这么表示：



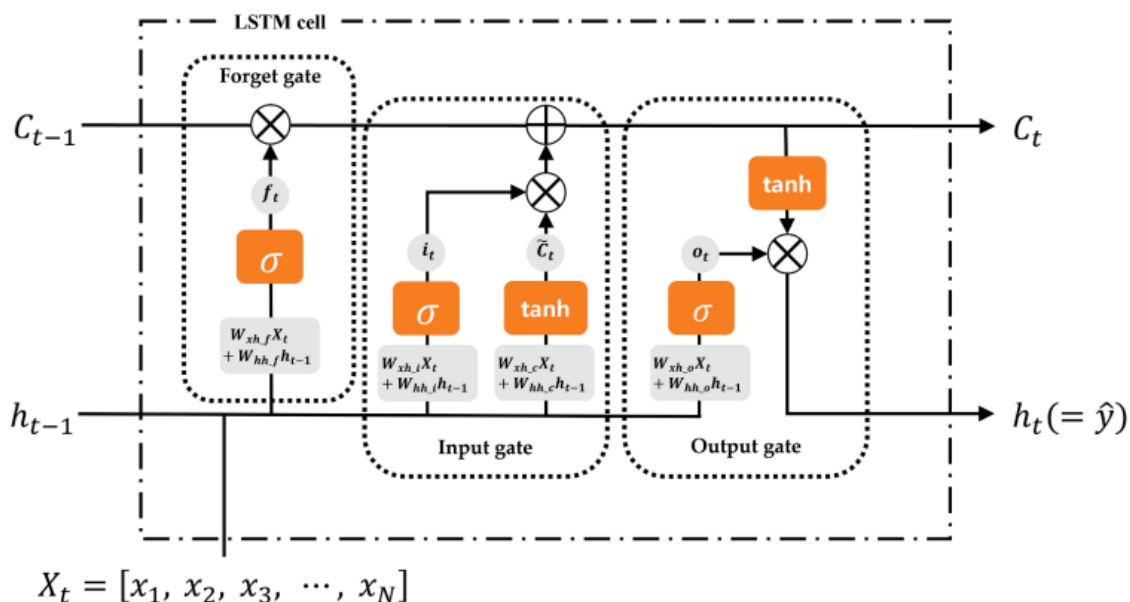
标准 RNN 中的重复模块包含单个层。

可以看到A在  $t - 1$  时刻的输出值  $h - 1$  被复制到了  $t$  时刻，与  $t$  时刻的输入  $x_t$  整合后经过一个带权重和偏置的  $\tanh$  函数后形成输出，并继续将数据复制到  $t + 1$  时刻。与上图朴素的RNN相比，单个LSTM单元拥有更加复杂的内部结构和输入输出：



LSTM 中的重复模块包含四个交互层。

## (3). 文中的讲解



LSTM每个单元的隐藏状态与普通RNN中的单元相同，但LSTM单元有一个额外的单元状态和三个门：遗忘门、输入门和输出门。单元状态  $C_t$  是对过去的直接存储，根据门的状态有长或短的记忆。每次有新的输入时，遗忘门和输入门都会更新细胞状态。根据公式（6）的计算，遗忘门决定了前一个单元状态  $C_{t-1}$  被遗忘的程度， $f_t$ 。请注意，sigma代表sigmoid函数。相反，输入门决定了临时细胞状态  $C_t$  被更新到下一个细胞状态  $C_t$  的程度，如公式（7）和公式（8）所示。临时细胞状态和输入门是由输入和先前的隐藏状态计算的。通过公式（9），下一个单元格状态由前一个单元格状态和遗忘门（ $f_t \times C_{t-1}$ ）与临时单元格状态和输入门（ $i_t \times C_t$ ）的乘积之和更新。输出门将新的单元格状态、输入和先前的隐藏状态进行核对，以确定输出  $o_t$  和新的隐藏状态  $h_t$ ，如公式(10)和公式(11)所表述的。

## 二、多步预测策略

对于一个单变量的多步预测，可以写成以下形式：

$$[\hat{y}_{t+1}, \hat{y}_{t+2}, \dots, \hat{y}_{t+H-1}, \hat{y}_{t+H}] = f(y_t, y_{t-1}, \dots, y_{t-d+2}, y_{t-d+1})$$

其中， $t$  代表当前时刻， $y$  代表过去的值， $\hat{y}$  代表预测值， $f$  代表预测模型。 $d$  代表回顾域， $H$  代表预测域。

当回顾域  $d$  不变时，随着  $H$  的增加，多步预测问题将会更加困难。所以为了让预测域足够大，文章给出了三个预测策略：

1. 递归(recursive)
2. 直接(direct)
3. 多入多出(MIMO)

### 1. 递归策略

递归策略只需要单个预测模型  $f_{Rec}$ ，训练后可以进行单步预测：

$$\hat{y}_{t+1} = f_{Rec}(y_t, y_{t-1}, \dots, y_{t-d+2}, y_{t-d+1})$$

进行一次单步预测以后，将预测值作为模型的输入，继续预测下一时刻的输出。这种方法很便捷，但是对误差敏感，随着预测域的增加会不断累计误差。

### 2. 直接策略

直接策略使用多个预测模型，每个模型预测一个时间的输出：

$$\begin{aligned} \hat{y}_{t+h} &= f_{Dir,h}(y_t, y_{t-1}, \dots, y_{t-d+2}, y_{t-d+1}) \\ h &\in \{1, \dots, H\} \end{aligned}$$

这种方法不会有误差累计，然而，时序信号之间的相关性没有得到考虑，因为每个未来的时间步长都是由独立的预测模型估计的。也就是说放弃了相关性提供的信息。

### 3. 多入多出策略

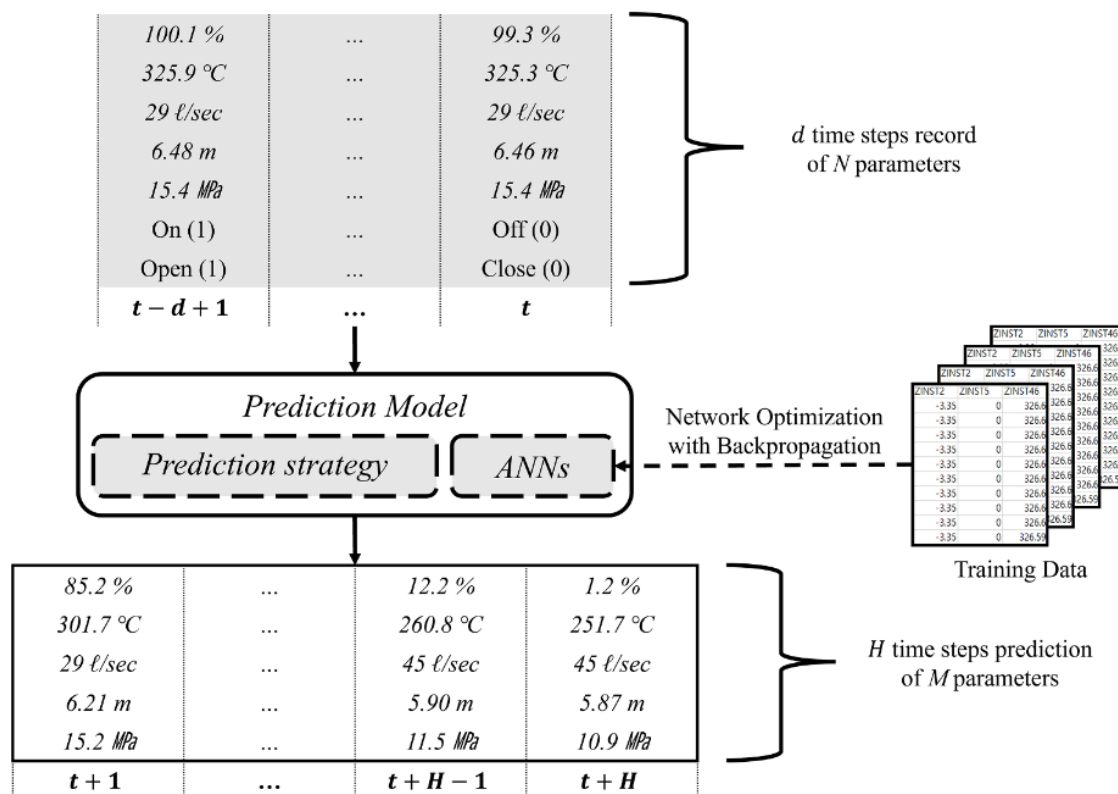
递归策略和直接策略本质上都是单步预测。MIMO 策略是一个多步预测策略，预测模型被训练用来一次性预测出接下来  $H$  时间的输出：

$$[\hat{y}_{t+1}, \hat{y}_{t+2}, \dots, \hat{y}_{t+H-1}, \hat{y}_{t+H}] = f_{MIMO}(y_t, y_{t-1}, \dots, y_{t-d+2}, y_{t-d+1})$$

MIMO策略可以避免递归和直接策略的缺点。同时，采用这种策略的预测模型可以考虑时间序列输入和输出之间的依赖关系。但在这种情况下，预测模型的训练可能会很复杂，因为这种方法没有分解和简化多步骤的预测问题；换句话说，MIMO策略没有减轻问题的复杂性，而预测模型应该解决这个问题。

### 三、基于多步预测策略和人工神经网络的控制对象参数预测模型

控制对象参数预测是指从控制对象参数的过去值中预测未来趋势。在这项研究中，文章提出了一个实时预测模型，以预测在特定情况下操作员设备控制后重要或安全相关参数的未来趋势。下图展示了拟议的预测模型的示意图。在该示意图中， $t$ 是当前的时间步长， $d$ 是回溯的时间步数（即回望）， $H$ 是预测的范围， $N$ 和 $M$ 分别是输入和输出参数的数量。



在本文的应用中，预测模型的输入参数包括：设备状态、来自传感器的仪器值和重要信号，这些信号可供典型的国家核电站仪器和控制系统使用。由于过去的值和趋势影响着未来的趋势，所以向预测模型提供了 $d$ 个时间步长的输入参数记录。预测模型接收一个大小为 $N \times d$ 的输入矩阵，估计一个大小为 $M \times H$ 的输出矩阵。

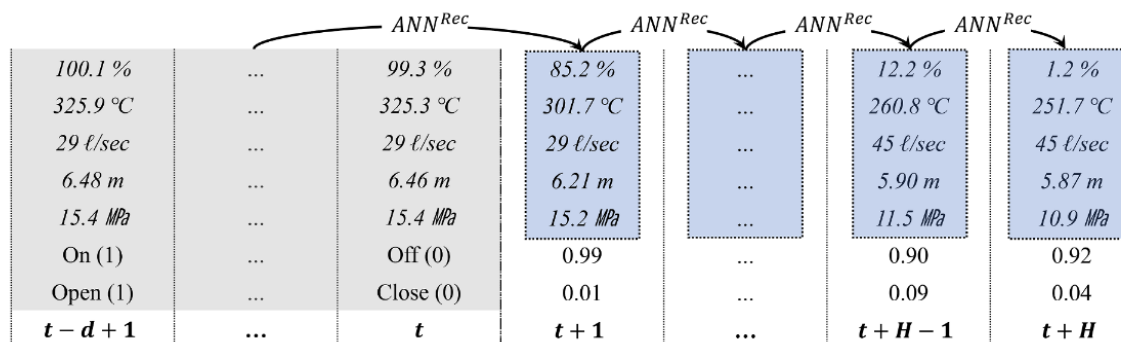
为了解释如此多的输入和输出值，预测模型采用了一个多步骤的预测策略和一个ANN。预测策略分解了预测问题，并确定了ANN的作用以及输入和输出。在训练阶段，神经网络优化器调整神经网络的内部参数，使训练数据与反向传播算法相一致。

正如第2节所介绍的，文章为单变量时间序列数据选择了三种候选的多步骤预测策略，特别是递归、直接和MIMO策略。需要注意的是，文章解决的预测问题不仅是多步骤的，而且是多变量的；因此，每个多步骤预测策略在与ANN结合时都会获得额外的特性，如以下各小节所述。

#### 1. 递归策略

递归策略是一种迭代的预测策略。在这种方法中，预测值被用来做进一步的预测。换句话说，一个ANN进行一步预测，预测值被递归用作ANN的输入。重复这个过程 $H$ 次，可以估计到 $t+H$ 的工厂参数。下图展示了这种预测策略。这个策略只需要一个单一的ANN。因此，与其他方法相比，神经网络训练需要较低的计算能力。这种方法的另一个优点是，从选择的预测范围来看，没有预测限制；如果训练的神经网络


足够精确，只需不断重复一步预测，就可以进行长期预测。此外，该策略反映相邻时间步长之间的相互依存关系。然而，这种策略有一个重要的缺点，即预测误差随着预测的重复而不断累积。另一个缺点是，一步的预测输出是下一步的输入，因此，输入和输出的参数数量必须相等，这可能会浪费计算资源。在我们的应用中，这种策略迫使我们不仅要预测M个目标参数的未来趋势，还要同时预测其余M-N个参数的未来趋势。



## 2. 直接策略


直接策略训练多个神经网络，并像单变量情况一样将每个神经网络投入到自己的时间步长。然而，在我们的应用中，网络预测了专用时间步长的多个参数。下图显示了由神经网络的同时预测进行的未来趋势预测。

这种策略避免了递归策略的两个缺点。首先，没有重复使用输出的错误积累。第二，输入参数的数量可以与输出参数的数量不同，这意味着我们可以将计算资源集中用于目标参数的预测。然而，这种策略需要比递归策略更高的计算能力，因为多个神经网络同时工作。此外，采用这种策略的神经网络只能在专门的时间步骤中考虑参数之间的相互依赖关系。此外，与递归策略相比，它需要更多的时间来训练神经网络，因为要把这种策略纳入预测模型，需要训练一组H个ANN。



## 3. 多入多出策略

MIMO策略为每个预测目标参数分配了一个神经网络。换句话说，神经网络的数量与目标参数（当前应用中的M）相同。与直接策略一样，多个神经网络一起工作来估计输出；下图说明了这种策略：





虽然这种策略与直接策略有大部分相同的特点，但它在神经网络的输出方面是不同的。每个神经网络估计一个特定参数的未来趋势，并思考其目标参数的**时间步长之间的相互依赖性**。一个缺点是，这种策略不包括参数之间的相互依赖性。

## 四、实验

本文进行了一个案例研究，以评估所提出的多步骤预测模型的可行性。为此，本文用多步骤预测策略和ANN的不同组合构建了各种预测模型。根据其包含的人工神经元的类型，神经网络具有不同的特点。本文选择了三种神经网络进行参数预测：MLP、RNN和LSTM。为了实现这些网络，本文使用了Keras API，这是一个用Python编写的高级应用编程接口，运行于机器学习框架Tensor-Flow。由于真实核电站的运行数据是保密的，本文选择了一个紧凑型核模拟器（CNS）作为目标控制对象，这是一个西屋1000兆瓦3回路工厂的简化模拟器。

在构建模型之前，必须首先定义预测模型的输入和输出。作为输出，本文选择25个预测目标参数。每个选定的参数都是在国家核电站紧急情况下运营商实施所需的应急操作程序时必须监测的参数。CNS应急操作程序包括一个称为关键安全功能树的工厂状态监测程序。关键安全功能（CSF）是指为确保电厂安全必须保留的NPP功能。在CNS中，有六个CSFs：反应堆堆芯的亚临界性、堆芯冷却、排热、反应堆冷却剂系统的完整性、安全壳的完整性和反应堆冷却剂库存。例如，CSF树程序要求操作人员通过安全壳预设、底盘水位和安全壳辐射水平来监测安全壳的完整性。像这样，CSF中总共有25个参数需要监测；下表列出了要预测的目标参数。

序号	参数
1	功率范围百分比(%)
2	中程范围启动率(DPM)
3	中程范围中子等级(A)
4	源范围启动速率（DPM)
5	堆芯出口温度(°C)
6	回路1热管段温度(°C)
7	回路2热管段温度(°C)
8	回路3热管段温度(°C)
9	增压器压力（kg/cm <sup>2</sup> ）
10	1号蒸汽发生器窄液位（%）
11	2号蒸汽发生器窄液位（%）
12	3号蒸汽发生器窄液位（%）
13	1号给水流量（m <sup>3</sup> /hr）
14	2号给水流量（m <sup>3</sup> /hr）
15	3号给水流量（m <sup>3</sup> /hr）
16	1号蒸汽发生器压力（kg/cm <sup>2</sup> ）

序号	参数
17	2号蒸汽发生器压力 (kg/cm <sup>2</sup> )
18	3号蒸汽发生器压力 (kg/cm <sup>2</sup> )
19	回路1冷管段温度(°C)
20	回路2冷管段温度(°C)
21	回路3冷管段温度(°C)
22	安全壳压力 (kg/cm <sup>2</sup> )
23	安全壳集水坑水位(m)
24	安全壳辐射 (mRem/hr)
25	稳压器液位 (%)

对于模型的输入，文章选择了在紧急操作程序中至少提到一次的每一个参数，用于三种不同的事故情景（详见下表）。在本研究中，总共有109个输入参数。其中，上述25个预测目标参数被列为输入参数，其余84个参数包括**阀门状态**（如主蒸汽隔离阀打开或关闭）、**部件状态**（如反应堆冷却剂补给泵状态）、**传感器的仪表值**（如反应堆容器水位）以及其他重要信号（如安全喷射启动标志）。

文章在建议的模型中把回视率（d）设为1。预测范围H应谨慎选择，因为它反映了长期预测和准确性之间的权衡：预测越远，预测的准确性越低。然而，并没有一个普遍的规则来确定最佳的预测范围。Nguyen等人（2020）调查了最近其他研究在2015-2019年期间在工业领域选择的各种预测范围（Nguyen等人，2020）。结果表明，大多数研究都进行了单步预测，而少数多步预测研究选择的预测水平线在**3到6步**之间。在本文的案例中，拟议模型的预测范围设定为**20**。在时间步骤之间有30秒的时间间隔，所提出的模型可以预测未来10分钟的参数趋势。

综上所述，所提出的模型应解决的问题是利用109×2的输入矩阵（即109个输入参数和2个时间步长[**当前和过去**]）估计25×20的输出矩阵（即25个预测目标参数和20个未来时间步长）。下面的小节详细介绍了紧急运行数据的程序分析和预测的ANN的构建。

## 1. 数据采集

本文使用CNS在核电站紧急情况下生成了运行数据，该CNS模拟了西屋公司基于SMABRE热-液压系统的三回路压水反应堆。SMABRE，代表小规模冷却剂损失事故，是一个基于假设和实验的简化一维节点化代码。虽然CNS不能模拟所有可能的现象和操作者的控制，但开放性和快速模拟能够产生大量的紧急操作数据。模拟的控制对象有一个带有反应堆核心的一次侧和一个带有涡轮机的二次侧。由反应堆堆芯产生的热量通过反应堆冷却剂转移到蒸汽发生器。利用转移的热量，蒸汽发生器将二次侧提供的水转化为蒸汽并供应给涡轮机。反应堆冷却剂的体积和压力由连接到一次侧的加压器控制，加压器的顶部有一个动力操作的泄压阀（PORV），以防止反应堆冷却剂过压。


在正常运行的情况下，预先假定了三种不同的国家核电站事故：冷却剂损失事故（LOCA），蒸汽发生器管破裂（SGTR），以及简单的反应堆跳闸。LOCA是由于一系列可能的事故导致的反应堆冷却剂的泄漏，并可能导致反应堆堆芯过热。在我们的模拟中，我们假设冷管（即从蒸汽发生器到反应堆堆芯的吸气管线）的断裂引发LOCA。SGTR是指蒸汽发生器中的热交换管破裂，可引发一次侧冷却剂的减压，并向二次侧释放放射性物质。我们假设有一个或两个管子破裂。本模拟中的简单反应堆跳闸是由于反应堆保护系统的故障而导致的非预期的反应堆跳闸。虽然它没有LOCA和SGTR那么严重，但这种情况下的电厂动态会迅速变化。



由于存在大量可能的操作员行动，我们分析了CNS紧急操作程序，以提取潜在的操作员行动场景。CNS应急操作程序由顺序组织的步骤组成，其中包含与电厂参数检查、程序转移和设备控制有关的说明。

首先，我们根据专业知识，确定了操作人员对事故作出适当反应时，达到每个程序步骤的时间。第二，我们区分了需要操作者行动的特定步骤。第三，我们假设在区分的步骤中，人的错误是以背景的方式出现的。例如，在CNS紧急操作程序中，E-0程序的第18步被确定为在SGTR后380秒到达，要求操作员打开PORV的关闭阀（见图9）。我们认为在这个步骤中可能出现的人为错误是操作人员错误地直接打开了PORV，而不是关闭阀；在控制界面中，PORV就在PORV关闭阀的旁边，而且打开关闭阀的前提动作是先将PORV设置为手动模式。在分析的基础上，我们最后考虑了各种操作者的动作时间。例如，在上面的例子中，一些方案反映出前提条件被正确执行，PORV截止阀在SGTR后320、350、380、410和450秒被无误打开，而其他方案反映出PORV在SGTR后320、350、380、410和450秒被无意中打开。最终，如表2所示，CNS编写并模拟了1,153种紧急操作方案。在所得到的1,153个操作数据用于训练预测模型之前，通过最小-最大归一化对参数值进行了重新调整，以防止由参数比例引起的问题。

总的来说，这篇文章之所以会产生下图的预测效果，是因为训练数据是以操作员进行了错误操作后模拟出的故障情况数据进行训练的，所以会产生这种曲线是因为有模拟的对应故障模拟的故障数据。



## 五、与《核电站热工水力系统工况预测与诊断方法研究》对比

### 1. 输入输出数据

两篇文章采集的输入数据有所不同，但是基本都围绕**温度**、**压强**和**流量**三者的测量值。本文还多了**阀门状态**（如主蒸汽隔离阀打开或关闭）、**部件状态**（如反应堆冷却剂补给泵状态）、**传感器的仪表值**（如反应堆容器水位）以及其他重要信号（如安全喷射启动标志）。

两篇文章的输出数据大致相同，都预测了各重要工况参数（**温度**、**压强**和**流量**）。

## 2. 预测能力

### (1). 本文

本文之所以能预测故障情况下比较神奇的趋势，是因为已经知道了故障情况。

### (2). 《核电站热工水力系统工况预测与诊断方法研究》第五章

这篇文章中，在进行预测之前，**已经使用故障诊断模型判明了核电站瞬态工况所属的故障类型**，因此预测模型可以仅针对单一故障工况进行训练。

## 3. 结合项目

结合这两篇文章，我们的项目要能够预测故障情况下的停堆问题，产生神奇的曲线，需要能够诊断出故障。

如果没有故障信息，或者故障数据，是无法预测出以下这种结果的。

